

Souad SADOUN

Théo Daguiet

Mohamed
AMGHAR

ANALYSE DE RADIOGRAPHIES PULMONAIRES COVIDE_19



Table des matières

1 Introduction au projet	4
1.1 Contexte métier	4
1.2 Contexte technique	4
1.3 Contexte économique	5
1.4 Contexte scientifique	5
2 Compréhension et manipulation des données	5
2.1 Déséquilibre des classes :	6
2.2 Taille et format des images :	6
2.3 Analyse de la structure du Dataset	7
3 Visualisations et Statistiques	7
3.1 Graphique 1 – Nombre d’images par catégorie	7
3.2 Graphique 2 – Pourcentage d’images par catégorie	8
3.3 Graphique 3 – COVID vs Autres catégories	9
3.4 Graphique 4 – Présence de doublons dans les images	10
3.5 Graphique 5 – Distribution des images par catégorie et format	11
3.6 Graphique 6 – Exemple d’image pour chaque catégorie	11
3.7 Graphique 7 – Intensité moyenne vs Écart-type	13
3.8 Graphique 8 – Contraste par classe (boxplot)	14
3.9 Graphique 9 – Intensité vs Entropie	15
3.10 Graphique 10 – Gradient des contours par classe	16
3.11 Graphique 11 – Matrice de corrélation des 5 features	17
4 Pre-processing et Feature Engineering	18
4.1 Les principales actions réalisées dans cette étape sont :	18
4.2 Nettoyage du dataset	19
4.3 Pre-processing – Normalisation et préparation des images	19
4.4 Visualisation :	19
4.5 Réduction du bruit – Gaussian Blur	20
4.6 Détection des contours et extraction de caractéristiques	21
4.7 Extraction de gradients – Filtre Sobel	22
4.8 Accentuation des contours – Filtre Laplacian	24
4.9 Morphologie Erosion et Dilatation	25
4.10 Zoom et rotation sur les images	26
4.11 PCA + détection d'outliers	26
4.12 Détection des valeurs aberrantes et analyse statistique des images	28
4.13 Analyse statistique des images	29
5 Perspective pour la modélisation	33
6 STEP 1 :– Baseline : Encodage des labels et train/test split	34

6.1 Objectif	34
6.2 Données et encodage des labels	34
6.3 Préparation des images pour le ML	34
6.4 Séparation train/test	35
6.5 Baseline : Modélisation initiale (Random Forest)	35
6.6 Analyse des résultats	36
7 - STEP 2 : Optimisation et analyse du modèle Random Forest	36
7.1 Objectif	36
7.2 Méthodologie	37
1) Pré-traitement des données	37
2) Transformation des images	37
3) Séparation des données	37
4) Optimisation du modèle Random Forest	37
5) Évaluation des modèles	37
6) Analyse qualitative	38
7.3 Meilleurs hyperparamètres Random Forest	38
7.4 Résultats Random Forest	38
7.5 Analyse des résultats Random Forest	40
7.6 Résultats KNN	43
7.7 Conclusion STEP 2	44
8 STEP 3 – Deep Learning + Boosting + Interprétation	45
8.1 Objectif	45
8.2 Préparation des données	45
8.3 Modèle CNN	45
8.4 Évaluation CNN	47
8.5 Interprétabilité – Grad-CAM	50
8.6 Gradient Boosting sur features CNN	52
8.7 Transfer Learning – Méthodologie et justification des choix	54
8.8 Transfer Learning – ResNet50 (modèle retenu)	56
8.9 Transfer Learning – VGG16	56
8.10 Transfer Learning – EfficientNetB0	57
8.11 Comparaison des modèles	57
8.12 Interprétabilité étendue – Grad-CAM (Transfer Learning) + SHAP	58
8.13 Conclusion de la modélisation	59
8.14 Conclusions scientifiques et métiers	59

1 Introduction au projet

Le projet a pour objectif de développer une méthode automatique d'aide à la classification de radiographies thoraciques afin d'identifier des cas compatibles avec le COVID-19, des poumons normaux, des opacités pulmonaires non-COVID et des pneumonies virales. L'approche repose sur l'analyse d'images médicales à l'aide de techniques de machine learning et de deep learning. Elle ne vise pas à remplacer un diagnostic médical ou un test biologique, mais à étudier le potentiel d'un outil d'aide à la décision dans des contextes où les radiographies sont rapidement disponibles.

1.1 Contexte métier

La pandémie de Covid-19 a mis en évidence la nécessité d'outils d'aide au diagnostic rapides et accessibles dans les hôpitaux. Les radiographies pulmonaires constituent un examen simple, peu coûteux et disponible dans la majorité des centres médicaux. Elles peuvent révéler certaines opacités pulmonaires compatibles avec une infection respiratoire, dont le COVID-19, mais ces signes ne sont pas spécifiques et doivent être interprétés par un professionnel de santé.

Cependant, l'interprétation manuelle reste chronophage et dépend fortement de l'expérience des radiologues, surtout lors des périodes de forte affluence. Un système automatisé de classification des radiographies permettrait d'assister les cliniciens en priorisant les cas suspects et en accélérant la prise de décision.

1.2 Contexte technique

Le projet consiste à développer un modèle de classification d'images multi-classes distinguant quatre catégories : *Covid*, *Normal*, *Lung Opacity* et *Viral Pneumonia*.

Les radiographies fournies sont des images en niveaux de gris au format PNG et de taille 299×299 pixels. Elles nécessitent un pre-processing spécifique comprenant le redimensionnement, la normalisation des intensités.

Ce pre-processing constitue une étape essentielle pour améliorer la qualité des données et optimiser les performances des modèles de Machine Learning utilisés dans l'étude.

1.3 Contexte économique

Un modèle performant pourrait contribuer à réduire les délais de triage radiologique, en fournissant une prédiction automatique en quelques secondes. Les délais d'interprétation humaine restent toutefois très variables selon les établissements, la charge de travail et l'organisation médicale.

Cette réduction du temps de traitement contribuerait à une meilleure gestion des flux hospitaliers, en particulier dans les services d'urgences.

Par ailleurs, dans certains contextes, une radiographie thoracique peut être plus accessible qu'un test moléculaire. Les coûts exacts varient fortement selon les pays, les systèmes de remboursement et les établissements ; cette approche doit donc être considérée comme un outil complémentaire, et non comme une alternative directe au diagnostic biologique.

1.4 Contexte scientifique

Le projet s'inscrit dans le domaine de la vision par ordinateur appliquée à la santé. L'objectif est de développer des modèles capables d'analyser automatiquement des images radiographiques pulmonaires pour détecter la présence de Covid-19 ou d'autres types de pneumonie.

Techniquement, cela implique :

- Extraction de caractéristiques des images, comme les textures, contrastes ou motifs spécifiques aux poumons atteints par le Covid-19.
- Application de modèles de deep learning, notamment les réseaux de neurones convolutifs (CNN), qui sont particulièrement efficaces pour la classification d'images médicales.
- Aide à l'analyse radiographique : le modèle apprend à différencier des images saines et pathologiques, ce qui peut soutenir le triage ou l'aide à la décision, sans se substituer au jugement clinique des radiologues.
- Contribution scientifique : le projet permet d'évaluer la pertinence des modèles d'IA sur des données réelles, de comparer les performances des algorithmes, et de proposer des améliorations pour la détection précoce de maladies pulmonaires à partir d'images radiographiques.

2 Compréhension et manipulation des données

Le projet utilise le COVID-19 Radiography Database disponible sur Kaggle, qui contient des images radiographiques pulmonaires classées en plusieurs catégories : COVID-19, Normal, Lung opacity et Viral pneumonia. Dans ce rapport, la classification est principalement menée sur quatre classes : COVID-19, Normal, Lung Opacity et Viral Pneumonia. Certains traitements exploratoires peuvent toutefois regrouper temporairement des classes pour analyser des oppositions plus simples, par exemple COVID vs autres catégories.

2.1 Déséquilibre des classes :

Le Dataset présente un déséquilibre notable entre les catégories : la classe Normal contient beaucoup plus d'images que les classes COVID-19 ou Viral pneumonia. Ce déséquilibre devra être pris en compte lors de la modélisation, par exemple en utilisant des techniques d'augmentation de données ou de rééchantillonnage.

2.2 Taille et format des images :

Toutes les images sont au format PNG et ont la même taille, ce qui facilite le pre-processing. Un redimensionnement peut être appliqué si nécessaire pour correspondre aux dimensions d'entrée requises par le modèle.

Ces caractéristiques sont essentielles pour orienter les étapes de pre-processing, d'augmentation des données et de modélisation du projet.

Le tableau ci-dessous présente les principales caractéristiques des variables contenues dans le Dataset, leur disponibilité, le type de données, le taux de valeurs manquantes et les traitements envisagés pour le pre-processing.

 Rapport exploration des données 								
N° Col	NOM DE LA COLONNE	DESCRIPTION	DISPONIBILITÉ DE LA VARIABLE A PRIORI	TYPE INFORMATIQUE	TAUX DE NA	GESTION DES NA	DISTRIBUTION DES VALEURS	REMARQUES DUR LES COLONNE
1	FILE NAME	Nom du fichier image	Oui	Object/String	0%	Aucun	Valeur unique	Identifiant unique de l'image
2	FORMAT	Format de l'image	Oui	Object/png	0%	Aucun	Catégorielle _ Binaire	Toutes les images sont PNG
3	SIZE	Dimension de l'image	Oui	Object/String	0%	Aucun	Quantitative	Même taille pour toutes les images
4	URL	Source de l'image	Oui	Object/String	0%	Aucun	valeur unique	Utilisé pour chargement

2.3 Analyse de la structure du Dataset

Le dataset utilisé dans ce projet est simple et bien structuré. Chaque image possède un identifiant unique et toutes les radiographies sont enregistrées au même format PNG avec une taille uniforme.

Cette homogénéité facilite considérablement la phase de pré-traitement. Même si les images sources ont une taille uniforme, des redimensionnements différents sont appliqués selon les modèles : 64×64 pour les modèles classiques, 256×256 pour certaines étapes exploratoires et 224×224 pour les architectures de transfer learning pré-entraînées.

La variable cible « Classe » est de type catégoriel et représente les différentes pathologies associées aux radiographies pulmonaires. Cependant, une analyse préliminaire met en évidence un déséquilibre notable entre les catégories.

Ce déséquilibre devra être pris en compte lors des étapes suivantes du projet, notamment :

- l'augmentation de données (data augmentation) ;
- la conception du modèle de classification ;
- l'évaluation des performances du modèle.

3 Visualisations et Statistiques

Le dataset a été analysé à travers plusieurs graphiques pour explorer la distribution des images, le déséquilibre des classes, la qualité technique des radiographies et les caractéristiques statistiques des images.

3.1 Graphique 1 – Nombre d'images par catégorie

Le graphique ci-dessous montre la répartition du nombre d'images par catégorie dans le Dataset. Il permet de visualiser le déséquilibre entre les différentes classes et d'identifier les éventuels ajustements nécessaires pour la modélisation.





Figure 1 – Nombre d'images par catégorie dans le dataset

Analyse :

On constate que la classe Normal est largement majoritaire par rapport aux classes COVID-19 et Pneumonia, qui sont minoritaires. Ce déséquilibre devra être pris en compte lors du pre-processing et de la modélisation, par exemple en appliquant des techniques d'augmentation des données ou de rééchantillonnage.

3.2 Graphique 2 – Pourcentage d'images par catégorie

Le graphique ci-dessous présente le pourcentage d'images dans chaque catégorie du dataset. Il permet de visualiser plus précisément le déséquilibre relatif entre les classes, en complément du graphique précédent qui montrait le nombre absolu d'images.



Analyse :

Le graphique confirme que la classe Normal est majoritaire, représentant une proportion beaucoup plus élevée que les classes COVID-19 et Pneumonia. Cette information est essentielle pour la planification du pre-processing et la stratégie de modélisation, car un modèle entraîné sur des données déséquilibrées pourrait être biaisé en faveur de la classe majoritaire.

3.3 Graphique 3 – COVID vs Autres catégories

Le graphique ci-dessous compare le nombre d'images de la classe COVID-19 avec celui des autres catégories regroupées. Il permet de mettre en évidence le déséquilibre important entre la classe COVID et les autres classes.





Figure 3 – Comparaison de la classe COVID-19 avec les autres catégories

Analyse :

On constate que la classe COVID-19 est nettement minoritaire par rapport aux autres catégories. Sans correction, ce déséquilibre pourrait conduire le modèle à sous-prédire les cas COVID, ce qui affecterait la fiabilité du diagnostic automatique. Des techniques d'augmentation de données ou de rééchantillonnage seront donc nécessaires pour compenser cette minorité

3.4 Graphique 4 – Présence de doublons dans les images

Le graphique ci-dessous illustre la présence éventuelle d'images en double dans le dataset. L'objectif est de vérifier que chaque image est unique, afin d'éviter que le modèle n'apprenne des exemples répétés plutôt que de véritables caractéristiques discriminantes.




Analyse :

Le graphique indique qu'aucun doublon exact n'a été détecté dans le dataset. Cette vérification réduit le risque de fuite par répétition d'images, mais ne garantit pas à elle seule l'absence de biais liés à la source des données, au protocole d'acquisition ou aux artefacts visuels.

3.5 Graphique 5 – Distribution des images par catégorie et format

Le graphique ci-dessous montre la répartition des images par catégorie et par format de fichier. Même si toutes les images du dataset actuel sont au format PNG, cette vérification permet de s'assurer de l'uniformité et d'anticiper d'éventuels problèmes si d'autres formats (comme JPG) étaient ajoutés à l'avenir.



Analyse :

Le graphique confirme que toutes les images sont au format PNG. Cette homogénéité facilite le pre-processing et garantit que le modèle n'aura pas à gérer différents formats d'image. Dans le cas où d'autres formats seraient introduits, un traitement spécifique pourrait être nécessaire avant l'entraînement.

3.6 Graphique 6 – Exemple d'image pour chaque catégorie

Le graphique ci-dessous montre un exemple représentatif d'image pour chaque catégorie du dataset (COVID-19, Normal, Lung Opacity, Viral Pneumonia). Cette visualisation permet de mieux comprendre les différences visuelles entre les classes et d'anticiper les difficultés que le modèle pourrait rencontrer pour les distinguer.

Exemple d'image pour chaque catégorie




Figure 6 – Exemple représentatif d'image par catégorie (COVID-19, Normal, Lung Opacity, Viral Pneumonia)

Analyse :

- COVID-19 : les radiographies montrent souvent des opacités diffuses, parfois bilatérales, correspondant aux infiltrats pulmonaires typiques du COVID.
- Normal : les poumons apparaissent clairs sans anomalies, constituant la référence pour la détection des pathologies.
- Lung Opacity (Non-COVID) : présence de zones d'opacité indiquant des infections pulmonaires ou inflammations différentes du COVID-19.
- Viral Pneumonia : opacités plus localisées ou motifs particuliers liés à la pneumonie virale.

Cette étape est essentielle pour :

- vérifier la qualité et la représentativité des images dans chaque classe,
- anticiper les difficultés du modèle pour différencier des classes visuellement similaires,
- sensibiliser à la nécessité de pre-processing (normalisation, redimensionnement, augmentation) pour améliorer les performances du modèle de classification.

3.7 Graphique 7 – Intensité moyenne vs Écart-type

Ce graphique représente, pour chaque radiographie, sa luminosité moyenne en fonction de la dispersion de ses pixels, afin de vérifier la qualité technique des images et de repérer d'éventuels cas de sous- ou de sur-exposition




Figure 7 – Relation entre l'intensité moyenne et l'écart-type des images


Analyse :

Ce nuage de points montre, pour chaque image, la relation entre la luminosité moyenne (intensité) et la variabilité des pixels (écart-type). On observe une tendance globale cohérente : les images plus lumineuses ont en général un écart-type plus élevé, ce qui est attendu en imagerie médicale.

Quelques points s'écartent de cette tendance (valeurs très faibles ou très élevées), ce qui peut correspondre à des radiographies sous-exposées, surexposées ou de qualité atypique ; ces cas devront être surveillés car ils peuvent perturber l'apprentissage du modèle.

3.8 Graphique 8 – Contraste par classe (boxplot)

Ce graphique montre la distribution du contraste pour chaque catégorie de radiographie, afin d'identifier si les images pathologiques présentent des variations d'intensité plus marquées que les images normales.



le boxplot compare la distribution du contraste entre les différentes classes. les radiographies pathologiques (COVID-19, Lung Opacity, Viral Pneumonia) semblent présenter globalement un contraste plus élevé et plus variable que la classe Normale. Cette tendance peut être liée à la présence d'opacités ou de structures anormales, mais elle doit être interprétée avec prudence car elle ne constitue pas une preuve médicale suffisante à elle seule.

On observe également un chevauchement important entre COVID-19 et Lung Opacity, ce qui confirme que ces deux types de pathologies sont visuellement proches et pourront être difficiles à distinguer uniquement à partir de statistiques simples d'intensité et de contraste ; cela justifie l'utilisation de caractéristiques plus riches (textures, CNN) pour la suite du projet.

3.9 Graphique 9 – Intensité vs Entropie

Ce graphique met en relation la luminosité moyenne et l'entropie de chacune des images, ce qui permet d'évaluer la complexité des textures radiographiques et de voir si les classes pathologiques sont plus hétérogènes que la classe normale.




Figure 9 – Relation entre l'intensité moyenne et l'entropie des images

Ce graphique met en relation l'intensité moyenne et l'entropie de chaque image, l'entropie mesurant la complexité ou la richesse des textures. Les images normales, plus homogènes, tendent à avoir une entropie plus faible, tandis que les radiographies présentant des anomalies (COVID-19, pneumonies) montrent des entropies plus élevées, en lien avec la présence de motifs d'opacités et d'irrégularités.

La dispersion des points pour la classe COVID-19 traduit une grande hétérogénéité des présentations radiologiques (formes légères à sévères), ce qui suggère que l'entropie peut aider à discriminer certains cas mais qu'elle devra être combinée à d'autres fonctionnalités pour obtenir une séparation robuste.

3.10 Graphique 10 – Gradient des contours par classe

Ce graphique compare, entre les différentes catégories, la force moyenne des gradients de contours, afin de quantifier la présence de bords et de structures internes liées aux opacités pulmonaires.




Figure 10 – Gradient des contours moyen par catégorie

Le gradient des contours mesure l'intensité des transitions entre les zones claires et foncées dans l'image. Les classes pathologiques présentent des valeurs de gradient plus fortes que la classe Normale, ce qui reflète la présence de nombreux bords internes liés aux opacités et aux structures anormales dans les poumons.

Cette observation suggère que les informations de bord, capturées par des filtres comme Sobel ou Canny, peuvent être utiles pour différencier certaines radiographies normales et pathologiques. Elles restent toutefois insuffisantes seules et doivent être combinées à des caractéristiques plus riches, notamment celles apprises par les CNN.

3.11 Graphique 11 – Matrice de corrélation des 5 features

Matrice de corrélation heatmap entre les 5 caractéristiques rapides : intensité moyenne, écart-type, contraste, entropie, gradient.




Figure 11 – Matrice de corrélation

La matrice de corrélation montre que certaines caractéristiques sont fortement redondantes, notamment la moyenne d'intensité, l'écart-type et le contraste, qui déterminent en grande partie la même dimension de variabilité des images. À l'inverse, l'entropie et le gradient apportent une information plus complémentaire, moins corrélée aux autres variables, ce qui justifie leur inclusion dans la PCA et dans la future modélisation.

Cette redondance partielle entre fonctionnalités explique également pourquoi la première composante principale capture une partie importante de la variance totale.

4 Pre-processing et Feature Engineering

Après l'exploration et la visualisation des données, la prochaine étape consiste à préparer et transformer les données pour le modèle. Cette phase comprend le pre-processing des images, afin de garantir qu'elles soient homogènes et exploitables, ainsi que le feature engineering, qui

permet d'extraire ou de transformer des informations pertinentes pour améliorer la performance du modèle de classification.

4.1 Les principales actions réalisées dans cette étape sont :

1. Redimensionnement des images : uniformisation des dimensions (par exemple 256×256 pixels) pour correspondre aux exigences des modèles de deep learning.
2. Normalisation des pixels : mise à l'échelle des valeurs de pixels entre 0 et 1 pour stabiliser l'entraînement des réseaux de neurones.
3. Encodage des labels : transformation des étiquettes textuelles en valeurs numériques pour la classification multi-classes.
4. Augmentation des données (Data Augmentation) : application de rotations, flips, zooms et variations de contraste sur les classes minoritaires afin de compenser le déséquilibre du dataset.
5. Vérification finale : contrôle de la lisibilité et de l'unicité des images, et vérification du format pour assurer un dataset fiable.

Ces étapes visent à fournir au modèle des données plus propres, cohérentes et exploitables, tout en réduisant partiellement l'effet du déséquilibre des classes. Elles améliorent la préparation des données, mais ne garantissent pas à elles seules la qualité clinique ou la généralisation du modèle.

4.2 Nettoyage du dataset

Avant tout traitement, nous avons vérifié et nettoyé notre dataset :

- Doublons : 0
- Fichiers manquants : 0
- Images corrompues : 0
- Nombre final d'images valides : 21 165

Toutes les images sont au format PNG et ont une taille homogène, ce qui nous permet de passer directement au prétraitement.

4.3 Pre-processing – Normalisation et préparation des images

Chaque image a été :

- Convertie en niveaux de gris pour réduire la complexité et la mémoire.
- Redimensionnée à 256×256 pixels pour standardiser les entrées du modèle.
- Normalisée avec des valeurs de pixels entre 0 et 1 pour stabiliser l'entraînement des réseaux de neurones.

Ces traitements permettent de créer un dataset homogène et prêt pour la modélisation, tout en garantissant que les caractéristiques essentielles des images sont conservées.

4.4 Visualisation :

Les premières images prétraitées sont affichées ci-dessous afin de vérifier que le prétraitement (conversion en niveaux de gris, redimensionnement et normalisation) a été effectué correctement.

Image pré-traitée : COVID




Figure 12 Exemple d'image prétraitée – catégorie COVID-19

Image pré-traitée : COVID



Figure 13 Exemple d'image prétraitée – catégorie COVID-19

Après normalisation et redimensionnement, il est important de réduire le bruit présent dans les radiographies afin de faciliter la détection des structures pulmonaires importantes. Pour cela, un filtre Gaussian Blur a été appliqué aux images.

Les objectifs de cette étape sont :

- Lissage des images pour atténuer le bruit provenant de la capture ou de la compression des radiographies.
- Préservation des caractéristiques essentielles, telles que les opacités, infiltrats ou autres anomalies pulmonaires.

Cette opération est cruciale pour préparer les images à des traitements plus précis comme les détections de contours (Canny, Sobel, Laplacian) et pour améliorer la qualité des features extraites par le modèle de deep learning.

Visualisation – Images après Gaussian Blur :

Exemple d'image après Gaussian Blur



Figure 16 Exemple d'image après application du filtre Gaussian Blur

Comme on peut le constater, le bruit est significativement réduit tout en conservant les structures essentielles des radiographies, ce qui améliore la fiabilité des étapes de feature extraction et la performance potentielle du modèle de classification.

4.6 Détection des contours et extraction de caractéristiques

Détection des contours – Filtre Canny

Le filtre Canny permet d'identifier les limites et contours des structures dans les images :

- ☐ Pré-requis : images converties en uint8 (0-255).
- ☐ Utile pour repérer des structures importantes pour la classification.

Voici une image après application du Filtre Canny

Exemple d'image après Canny Edge




Figure 17 – Contours détectés avec le filtre Canny

Les contours des poumons et les anomalies sont mis en évidence, ce qui permet au modèle de mieux identifier les structures importantes sur les radiographies.

4.7 Extraction de gradients – Filtre Sobel

Le filtre Sobel met en évidence les bords verticaux de l'image :

- Calcul du gradient sur l'axe X.
- Permet de mieux détecter les transitions d'intensité et détails importants.

Voici une image après application du Filtre Sobel

Exemple d'image après Sobel Filter




Figure 18 – Gradients verticaux extraits avec le filtre Sobel

Les images présentent des bords verticaux accentués afin d'enrichir les caractéristiques extraites pour le modèle.

4.8 Accentuation des contours – Filtre Laplacian

Le filtre Laplacien permet de détecter les détails fins et changements rapides d'intensité

Voici une image après application du Filtre Laplacian

Exemple d'image après Laplacian




Figure 19 – Contours et détails fins détectés avec le filtre Laplacian

L'image ci-dessus met en évidence les contours et les détails fins des radiographies, ce qui permet d'extraire des caractéristiques supplémentaires pour le modèle.


4.9 Morphologie Erosion et Dilatation

Pour améliorer la qualité des images tout en conservant les structures essentielles :

- Érosion : cette opération morphologique réduit les petites zones lumineuses ou bruitées, ce qui permet de nettoyer les radiographies et de supprimer les artefacts.
- Dilatation : après érosion, la dilatation restaure les structures importantes des poumons, garantissant que les contours et les formes significatives restent visibles pour le modèle.

Illustration : ci-dessous, une image montre l'effet combiné de l'érosion et de la dilatation sur une radiographie, avec les contours des poumons et les anomalies mieux définis.

Comparaison des étapes de pré-traitement et feature engineering



-
- ❖ Chaque transformation améliore progressivement la qualité et l'information des images.
 - ❖ Les contours et détails fins sont de plus en plus visibles, ce qui facilite l'apprentissage du modèle.

4.10 Zoom et rotation sur les images

Le zoom consiste à effectuer un recadrage centré sur la région pulmonaire, puis à redimensionner l'image à 256×256, de façon à conserver le format d'entrée tout en mettant davantage l'accent sur les zones d'intérêt. Un zoom de l'ordre de 10 à 15% permet de réduire l'influence des bordures et du fond tout en préservant les structures pulmonaires essentielles. En complément, une rotation légère autour du centre (par exemple de 15°) génère des vues légèrement inclinées sans déformer les poumons, ce qui simule des variations réalistes de position du patient.




Figure 21 1 Zoom et rotation sur les images

Analyse :

Cette augmentation de données est particulièrement utile pour les classes minoritaires, notamment COVID-19 : en générant des versions zoomées des radiographies, le modèle est exposé à des variantes où les opacités pulmonaires sont plus centrales et plus visibles. Cela renforce la capacité du modèle à détecter les motifs d'anomalies, tout en l'entraînant à être plus robuste aux variations de cadrage rencontrées en pratique clinique.

4.11 PCA + détection d'outliers

Les graphiques de PCA projettent les cinq fonctionnalités extraites dans un espace de dimension réduite pour visualiser la structure globale des données, tandis que la détection d'outliers met en évidence les radiographies les plus atypiques, souvent associées aux cas COVID extrêmes ou techniques particulières

PCA – Structure globale des fonctionnalités




Figure 22 – Projection PCA et détection des outliers

Analyse :

La PCA a été réalisée sur les cinq caractéristiques rapides (intensité moyenne, écart-type, contraste, entropie, gradient) afin de reprendre l'information dans un espace de dimension réduite. La première composante principale capture l'essentiel de la variance et représente une sorte d'axe « niveau d'anomalie radiologique », combinant intensité, contraste et texture. Sur

le nuage de points, les classes normales et pathologiques se répartissent différemment le long de cet axe, ce qui montre que même des caractéristiques simples permettent déjà de distinguer partiellement les images saines des images atteintes, même si un chevauchement subsiste entre certaines pathologies comme COVID-19 et Lung Opacity.

4.12 Détection des valeurs aberrantes et analyse statistique des images

Pour identifier les images les plus atypiques dans l'espace des features, la distance de Mahalanobis a été utilisée sur les projections PCA des images.

Méthodologie :

- Calcul de la distance de Mahalanobis pour chaque image dans l'espace PCA.
- Seuil au 95e percentile pour repérer les observations considérées comme aberrantes (~5 % des images).

Détection de valeurs aberrantes (distance de Mahalanobis)




Figure 23 – Détection des valeurs aberrantes avec la distance de Mahalanobis

données. Un seuil au 95e percentile permet de repérer environ 5% d'images considérées comme aberrantes.

Une proportion importante de ces outliers appartient à la classe COVID-19, ce qui suggère que certains cas COVID présentent des motifs radiographiques particulièrement atypiques (formes très sévères, distributions d'opacités inhabituelles ou qualité technique différente). Ces images extrêmes doivent être examinées avec attention : elles sont à la fois informatives pour comprendre la variabilité clinique et éventuellement délicates pour l'apprentissage, d'où l'intérêt de les utiliser de façon ciblée en augmentation des données.

4.13 Analyse statistique des images

Pour compléter la visualisation et le pré-processing, nous avons réalisé une analyse statistique simple sur les images prétraitées (niveaux de gris, redimensionnées et normalisées) :

Objectifs :



- Comprendre la distribution des pixels dans les images.
- Identifier d'éventuelles différences globales entre les catégories, notamment COVID vs Normal.
- Vérifier la qualité et l'homogénéité du pré-processing avant la modélisation.

Mesures calculées :

- Moyenne des intensités par image : indique la luminosité moyenne des radiographies.
- Écart-type des intensités : mesure la variation ou le contraste dans chaque image.
- Distribution des pixels : permet de détecter les différences de contraste ou de luminosité entre catégories.

Visualisation :

Histogramme des moyennes d'intensité des images



Comparaison des moyennes d'intensité entre images COVID et Normal.




Figure 26 – Comparaison des intensités moyennes entre images COVID et Normal

Afin d'évaluer les différences globales de luminosité entre les catégories, nous avons comparé les moyennes d'intensité des images COVID et Normal.

Analyse :

- Les images présentent une luminosité moyenne homogène, ce qui confirme l'efficacité du pré-processing (normalisation).
- L'écart-type indique que certaines images ont plus de contraste, probablement liées à la présence d'opacités ou anomalies.
- La comparaison COVID vs Normal révèle des différences légères dans l'intensité globale, confirmant que ces caractéristiques peuvent être exploitées par le modèle.
- Moyenne globale des images : 0,551 → indique la luminosité moyenne des radiographies après normalisation.
- Écart-type global des images : 0,210 → mesure la variation des pixels et l'hétérogénéité des radiographies.

Cette analyse confirme que les images présentent des caractéristiques distinctes entre les classes, ce qui peut être exploité pour enrichir les features du modèle de classification. Les images COVID et Normal montrent des distributions d'intensité différentes, fournissant un signal discriminant pour le modèle.

5 Perspective pour la modélisation

Le pre-processing et le feature engineering réalisés préparent efficacement le dataset pour la phase de modélisation. Les actions menées assurent que les images sont homogénéisées, normalisées et prêtes à être exploitées par des modèles de deep learning tels que les réseaux de neurones convolutifs (CNN).

Les points clés sont les suivants :

- Homogénéisation et normalisation : les images présentent désormais des dimensions uniformes et des valeurs de pixels normalisées, ce qui stabilise l'entraînement des modèles et réduit l'influence du bruit.
- Filtres appliqués : l'utilisation de Gaussian Blur, Canny, Sobel, Laplacian ainsi que des opérations morphologiques (érosion et dilatation) permet de mettre en évidence des caractéristiques importantes, facilitant la distinction entre classes.
- Statistiques descriptives : les mesures telles que la moyenne, l'écart-type et la distribution des pixels fournissent des informations additionnelles pouvant enrichir le modèle ou guider le choix des paramètres.

Cette étape améliore la qualité technique des données, réduit certains bruits et met en évidence des informations potentiellement pertinentes pour la classification automatique des radiographies. Elle constitue une base solide pour la modélisation, tout en nécessitant une évaluation rigoureuse des performances et des biais.

6 STEP 1 :– Baseline : Encodage des labels et train/test split

6.1 Objectif

L'objectif de cette étape est de préparer le dataset pour l'entraînement de modèles de machine learning classiques tels que Random Forest ou SVM. Cela comprend l'encodage des labels, la transformation des images en vecteurs exploitables par les modèles, ainsi que la séparation du dataset en ensembles d'entraînement et de test.

6.2 Données et encodage des labels

Le dataset utilisé contient 21 165 images réparties en quatre catégories :

- Normal : 10 192 images
- Lung Opacity : 6 012 images
- COVID : 3 616 images
- Viral Pneumonia : 1 345 images

Afin de permettre leur utilisation par les algorithmes de machine learning, les labels ont été convertis en valeurs numériques selon l'encodage suivant :

- COVID → 0
- Lung Opacity → 1
- Normal → 2
- Viral Pneumonia → 3

6.3 Préparation des images pour le ML

Pour réduire la charge mémoire et accélérer le processus d'entraînement, les images ont été redimensionnées à 64 × 64 pixels.

- Dimension du dataset après redimensionnement (shape) : (21 165, 64, 64)

Ensuite, chaque image a été transformée en un vecteur 1D contenant 4 096 valeurs afin de les rendre compatibles avec les modèles de la bibliothèque scikit-learn.

- Dimension finale du dataset (shape) : (21 165, 4 096)

6.4 Séparation train/test

Le dataset a été divisé en deux ensembles :

- 80 % pour l'entraînement : 16 932 images
- 20 % pour le test : 4 233 images

Une stratification des classes a été appliquée afin de conserver la même proportion de chaque catégorie dans les ensembles d'entraînement et de test.

6.5 Baseline : Modélisation initiale (Random Forest)

- Accuracy globale : 81,95 %
- Classification par classe :

Classe	Precision	Recall	F1-score	Support
COVID	0.87	0.69	0.77	723
Lung_Opacity	0.80	0.74	0.77	1 203
Normal	0.80	0.92	0.86	2 038
Viral Pneumonia	0.93	0.78	0.85	269




Figure 28 – Matrice de confusion Random Forest

6.6 Analyse des résultats

L'accuracy globale obtenue de 81,95 % montre que le modèle Random Forest est capable de distinguer correctement la majorité des radiographies pulmonaires.

L'analyse par classe révèle toutefois certaines différences de performance :

- La classe Normal est la mieux reconnue avec un recall de 0,92, ce qui indique que la majorité des images normales sont correctement identifiées.
- La classe COVID présente encore un nombre non négligeable de faux négatifs, avec un recall de 0,69, ce qui signifie que certaines radiographies COVID sont classées dans d'autres catégories.
- La classe Viral Pneumonia, malgré un nombre d'images plus limité, est relativement bien identifiée par le modèle.

Conclusion

Ces résultats mettent en évidence certaines limites des modèles de Machine Learning classiques appliqués directement sur des images brutes.

Ils soulignent notamment l'intérêt :

1. De redimensionner et normaliser les images pour faciliter l'apprentissage.
2. D'utiliser des modèles plus adaptés à l'analyse d'images, tels que les réseaux de neurones convolutifs (CNN).
3. D'appliquer des techniques d'augmentation de données (data augmentation) afin d'améliorer la performance sur les classes minoritaires.

7 - STEP 2 : Optimisation et analyse du modèle Random Forest

7.1 Objectif

Cette étape vise à optimiser les modèles de Machine Learning classiques pour la classification des radiographies pulmonaires et à analyser plus finement leurs performances.

Les objectifs principaux sont :

- Évaluer la performance globale du modèle.
- Identifier les classes correctement détectées et celles présentant davantage d'erreurs.

- Comprendre les limites des modèles classiques avant de passer à des approches plus avancées comme les CNN.

7.2 Méthodologie

La méthodologie suivie comprend plusieurs étapes :

1) Pré-traitement des données

Les images ont été redimensionnées à 64×64 pixels et normalisées entre 0 et 1 afin d'améliorer la stabilité de l'apprentissage.

2) Transformation des images

Chaque image a été aplatie (flattening) pour être transformée en vecteur 1D, ce qui permet leur utilisation avec des modèles de machine learning classiques.

3) Séparation des données

Le dataset a été divisé en :

- 80 % pour l'entraînement
- 20 % pour le test

4) Optimisation du modèle Random Forest

Une recherche d'hyperparamètres a été réalisée à l'aide de RandomizedSearchCV afin d'identifier la configuration la plus performante.

Les paramètres optimisés incluent :

- `n_estimators` : nombre d'arbres dans la forêt
- `max_depth` : profondeur maximale des arbres
- `min_samples_split` : nombre minimal d'échantillons nécessaires pour diviser un nœud
- `min_samples_leaf` : nombre minimal d'échantillons dans une feuille

5) Évaluation des modèles

Les modèles ont été évalués à l'aide de plusieurs métriques :

- Accuracy globale
- F1-score macro
- F1-score micro
- Matrice de confusion
- Analyse des performances par classe

6) Analyse qualitative

Une analyse qualitative a également été réalisée en observant les images mal classées afin d'identifier les principales sources d'erreur.

Modèle KNN :

- K-Nearest Neighbors avec k = 5, distance euclidienne
- Classification basée sur la majorité des voisins les plus proches
- Sensible au bruit et à la haute dimension des images

7.3 Meilleurs hyperparamètres Random Forest

L'optimisation a permis d'identifier la configuration suivante :

```
{'n_estimators': 150, 'min_samples_split': 2, 'min_samples_leaf': 1, 'max_depth': None}
```

Cette configuration correspond à une forêt d'arbres relativement profonde, avec un nombre d'arbres suffisant pour assurer une bonne stabilité et une capacité de généralisation correcte.

7.4 Résultats Random Forest

a) Performance globale

Les performances du modèle optimisé sont les suivantes :

- Accuracy : 82,28 %
- F1-score macro : 0,8169
- F1-score micro : 0,8228

Ces résultats montrent que le modèle est capable de classer correctement la majorité des images, tout en conservant un équilibre raisonnable entre les différentes classes.

b) Performance par classe


=== Tableau synthétique par classe ===

COVID	Precision: 0.90	Recall: 0.70	F1-score: 0.79	Support: 723.0
Lung_Opacity	Precision: 0.80	Recall: 0.74	F1-score: 0.77	Support: 1203.0
Normal	Precision: 0.81	Recall: 0.92	F1-score: 0.86	Support: 2038.0
Viral Pneumonia	Precision: 0.95	Recall: 0.80	F1-score: 0.87	Support: 269.0

L'analyse par classe met en évidence les points suivants :


- La classe Normal est la mieux détectée (recall $\approx$ 0,92).
- La classe COVID présente encore un nombre important de faux négatifs, ce qui est particulièrement critique dans un contexte médical.

La matrice de confusion permet de visualiser les principales erreurs du modèle, notamment les confusions entre COVID et Normal.



Visualisation qualitative des erreurs :

- Analyse des images mal classées pour comprendre les motifs de confusion et les limitations du modèle.



7.5 Analyse des résultats Random Forest

L'analyse détaillée met en évidence plusieurs observations importantes :

- Normal : très bien détectée par le modèle (recall 0,92).
- COVID : présence notable de faux négatifs (recall 0,69).
- Viral Pneumonia : malgré un effectif faible, le modèle détecte correctement certains patterns globaux.
- Principales confusions : Les erreurs les plus fréquentes concernent :
COVID ↔ Normal

Cela peut s'expliquer par la similarité visuelle entre certaines radiographies, notamment dans les cas peu avancés.


- Limite du flattening

La transformation des images en vecteurs 1D entraîne une perte de l'information spatiale, ce qui empêche le modèle de capturer correctement les structures pulmonaires complexes, telles que :

- les textures

- les opacités
- les motifs localisés dans les poumons.


Analyse complémentaire




□ Importance des features : certains pixels ont un poids élevé dans la décision finale.

□ Distribution des probabilités prédites :

Probabilités proches de 1 → forte confiance Probabilités proches de 0,5 → incertitude



- Courbes ROC et AUC : certaines classes comme COVID présentent des AUC légèrement inférieures.



- Confusions critiques COVID vs Normal : permet d'identifier visuellement les motifs de confusion.

Exemples de confusions critiques COVID vs Normal

COVID mal classé → Normal




COVID mal classé → Normal




COVID mal classé → Normal



Normal mal classé → COVID



Normal mal classé → COVID



Normal mal classé → COVID



7.6 Résultats KNN

a) Performance globale

Le modèle KNN obtient une accuracy de 77,39 %, inférieure à celle du Random Forest.


b) Classification report KNN

```
=== Classification Report - KNN ===
```

	precision	recall	f1-score	support
COVID	0.73	0.65	0.69	723
Lung_Opacity	0.72	0.69	0.70	1203
Normal	0.81	0.86	0.84	2038
Viral Pneumonia	0.85	0.88	0.87	269
accuracy			0.78	4233
macro avg	0.78	0.77	0.77	4233
weighted avg	0.78	0.78	0.78	4233

c) Matrice de confusion KNN

Visualisation similaire à Random Forest, montre des confusions entre COVID et Normal.



d) Analyse KNN

Les observations principales sont les suivantes :

- Le modèle est basé uniquement sur la proximité entre images.
- Il est très sensible à la dimension élevée des données.
- Ses performances restent correctes ($\sim 0,78$) mais inférieures à Random Forest ($\sim 0,82$).
- Les classes Normal et Viral Pneumonia sont mieux reconnues que COVID, ce qui confirme la difficulté à détecter certaines pathologies.

7.7 Conclusion STEP 2

Les modèles Random Forest et KNN constituent des baselines solides pour la classification des radiographies pulmonaires.

Le Random Forest obtient les meilleures performances avec une accuracy d'environ 82 %.

Cependant, plusieurs limites apparaissent :

- Perte d'information spatiale liée au flattening
- Sensibilité au bruit pour KNN

Ces limites justifient l'exploration de méthodes plus avancées.

Perspectives :

Les améliorations envisagées incluent :

- L'utilisation de CNN (Convolutional Neural Networks) pour exploiter la structure spatiale des images
- L'application de data augmentation
- L'utilisation de méthodes d'interprétabilité comme Grad-CAM pour visualiser les zones importantes dans les radiographies.

8 STEP 3 – Deep Learning + Boosting + Interprétation

8.1 Objectif

Cette étape vise à explorer des approches plus avancées basées sur le Deep Learning afin d'améliorer la classification des radiographies pulmonaires. Les objectifs principaux sont les suivants :

- Implémenter et évaluer un modèle de réseau de neurones convolutif (CNN) pour la classification d'images médicales en quatre catégories : COVID, Lung Opacity, Normal et Viral Pneumonia.
- Extraire les caractéristiques (features) apprises par le CNN afin de les exploiter dans un modèle de Gradient Boosting.
- Étudier l'interprétabilité du modèle en utilisant la méthode Grad-CAM, permettant de visualiser les régions de l'image influençant la décision du réseau.

8.2 Préparation des données

Le dataset utilisé pour cette étape contient 21 165 radiographies pulmonaires.

Les données ont été organisées selon la répartition suivante :

- 80 % pour l'entraînement
- 20 % pour la validation

Les images sont réparties en quatre classes principales :

- COVID
- Lung Opacity
- Normal
- Viral Pneumonia

Pour permettre l'apprentissage du CNN, les labels ont été encodés sous forme de vecteurs one-hot vectors, une représentation adaptée aux modèles de classification multi-classes utilisant une fonction Softmax..

8.3 Modèle CNN

a) Architecture

Le modèle de CNN utilisé est constitué de plusieurs couches permettant d'extraire progressivement les caractéristiques visuelles des radiographies.

L'architecture comprend :

- 2 couches convolutionnelles permettant de détecter les motifs visuels dans les images + MaxPooling pour réduire la dimension des cartes de caractéristiques

- Flatten transformant les cartes de caractéristiques en vecteur
- Dense de 128 neurones permettant l'apprentissage de représentations plus complexes + Dropout (0.5) afin de limiter le surapprentissage
- Dense de sortie Softmax composée de 4 neurones, correspondant aux quatre classes du dataset

Cette architecture permet au modèle de capturer les motifs visuels caractéristiques des différentes pathologies pulmonaires.

b) Paramètres d'entraînement

Le modèle a été entraîné avec les paramètres suivants :

- Optimiseur : Adam
- Fonction de perte (Loss) : Categorical Crossentropy
- Batch size : 16
- Nombre d'époques (Epochs) : 30

Afin d'améliorer la stabilité de l'entraînement et d'éviter le surapprentissage, deux techniques ont été utilisées :

- EarlyStopping avec une patience de 5 époques basé sur la métrique val_accuracy
- ModelCheckpoint permettant de sauvegarder automatiquement le meilleur modèle obtenu pendant l'entraînement.

c) Détails du modèle

Total params : 110 596 (Trainable : 110 148, Non-trainable : 448)

Couche de sortie : 4 neurones Softmax correspondant aux classes COVID, Lung Opacity, Normal et Viral Pneumonia

Model: "functional_5"

Layer (type)	Output Shape	Param #
input_layer_1 (InputLayer)	(None, 128, 128, 1)	0
conv2d_3 (Conv2D)	(None, 128, 128, 32)	320
batch_normalization_3 (BatchNormalization)	(None, 128, 128, 32)	128
max_pooling2d_3 (MaxPooling2D)	(None, 64, 64, 32)	0
conv2d_4 (Conv2D)	(None, 64, 64, 64)	18,496
batch_normalization_4 (BatchNormalization)	(None, 64, 64, 64)	256
max_pooling2d_4 (MaxPooling2D)	(None, 32, 32, 64)	0
conv2d_5 (Conv2D)	(None, 32, 32, 128)	73,856
batch_normalization_5 (BatchNormalization)	(None, 32, 32, 128)	512
max_pooling2d_5 (MaxPooling2D)	(None, 16, 16, 128)	0
features	(None, 128)	0

8.4 Évaluation CNN

a) Performance globale

- Accuracy validation : 50 %
- Ce résultat montre une mauvaise généralisation, malgré un entraînement correct sur le dataset d'entraînement.

b) Classification Report

- Accuracy globale : 0.50
- Macro F1-score : 0.20
- Weighted F1-score : 0.36
- Total images validation : 4 233


```

=== Classification Report ===
              precision    recall  f1-score   support


     COVID              1.00      0.00      0.00        723
  Lung_Opacity          0.49      0.08      0.13       1203
         Normal          0.50      0.98      0.66       2038
  Viral Pneumonia        0.00      0.00      0.00        269

 accuracy              0.50              4233
 macro avg              0.50      0.27      0.20       4233
 weighted avg           0.55      0.50      0.36       4233

```

c) Matrice de confusion

- o Le modèle prédit majoritairement la classe Normal
- o Faible performance pour les classes pathologiques (COVID, Lung Opacity, Viral Pneumonia)




d) Courbes d'apprentissage

Les courbes d'apprentissage permettent d'analyser l'évolution des performances du modèle au cours de l'entraînement et d'identifier d'éventuels problèmes tels que le surapprentissage (overfitting) ou le sous-apprentissage (underfitting).

Plusieurs observations peuvent être faites à partir de ces courbes :

- Lorsque la loss d'entraînement diminue tandis que la loss de validation reste stable ou augmente, cela indique généralement un surapprentissage : le modèle apprend trop précisément les données d'entraînement et perd sa capacité de généralisation.
- À l'inverse, si les valeurs de loss et d'accuracy sont proches entre l'entraînement et la validation, cela suggère que le modèle possède une bonne capacité de généralisation et qu'il parvient à apprendre des patterns pertinents.

L'analyse de ces courbes constitue donc un outil important pour évaluer la qualité de l'apprentissage et ajuster les paramètres du modèle si nécessaire.



8.5 Interprétabilité – Grad-CAM

a) Objectif


L'objectif de cette analyse est d'améliorer l'interprétabilité du modèle CNN en visualisant les zones de l'image qui influencent le plus la décision du CNN.

La méthode Grad-CAM (Gradient-weighted Class Activation Mapping) permet de générer des cartes de chaleur indiquant les régions de l'image sur lesquelles le modèle se concentre pour effectuer sa prédiction.

Cette approche est particulièrement importante dans le contexte médical, car elle aide à vérifier si le modèle semble s'appuyer sur des zones pulmonaires pertinentes plutôt que sur des éléments non pertinents de l'image. Elle ne constitue cependant pas une preuve formelle d'un raisonnement médical correct.

b) Expérimentation

- Images sélectionnées : idx = 0, 10, 20
- Méthode :
 - o Génération de la heatmap à partir de la dernière couche convolutionnelle
 - o Superposition sur l'image originale
 - o Affichage de la classe prédite



c) Observations

L'analyse des visualisations obtenues avec la méthode Grad-CAM met en évidence plusieurs éléments intéressants concernant le comportement du modèle.

Dans les exemples visualisés, les zones d'activation semblent se concentrer principalement sur les régions pulmonaires, ce qui suggère que le modèle porte au moins partiellement son attention sur des zones médicalement pertinentes de l'image.

Pour les radiographies classées comme Normal, l'activation apparaît généralement plus homogène sur l'ensemble des poumons, traduisant l'absence de motifs pathologiques particuliers.

En revanche, pour les images présentant des pathologies, les zones d'activation sont davantage localisées autour des opacités pulmonaires ou des zones présentant des anomalies visibles.

Ces observations suggèrent que le CNN apprend certaines caractéristiques visuelles utiles pour la classification. Elles renforcent l'intérêt de l'approche, mais doivent être interprétées comme une analyse exploratoire et non comme une validation clinique du modèle.

d) Intérêt scientifique

L'utilisation de la méthode Grad-CAM présente plusieurs avantages importants dans l'analyse des modèles de deep learning appliqués à l'imagerie médicale.

Tout d'abord, elle permet une validation visuelle du raisonnement du réseau de neurones, en montrant précisément quelles zones de l'image ont influencé la décision du modèle.

Ensuite, cette approche contribue à renforcer la confiance dans les prédictions du modèle, en vérifiant que l'algorithme se concentre sur des régions médicalement pertinentes, notamment les zones pulmonaires.

Enfin, l'interprétation visuelle fournie par Grad-CAM peut faciliter la compréhension des décisions du système d'intelligence artificielle. Son usage en contexte clinique réel nécessiterait toutefois une validation externe, une revue par des experts médicaux et une évaluation prospective.

8.6 Gradient Boosting sur features CNN

a) Extraction des features

Afin d'améliorer les performances de classification, les caractéristiques extraites par le CNN ont été utilisées comme entrée pour un modèle de Gradient Boosting.

Les features ont été extraites à partir de la couche GlobalAveragePooling2D, qui permet de résumer les cartes de caractéristiques du réseau en un vecteur compact.

Chaque image est ainsi représentée par un vecteur de 128 caractéristiques, correspondant aux informations visuelles apprises par le réseau de neurones.

b) Classifieur Gradient Boosting

Le classifieur utilisé est un modèle de Gradient Boosting, configuré avec les paramètres suivants :

`n_estimators = 300`

`random_state = 42`

Ce modèle a été entraîné sur les features extraites par le CNN, ce qui permet de combiner la puissance d'extraction de caractéristiques du deep learning avec l'efficacité des algorithmes de boosting pour la classification.

c) Performances obtenues

Les résultats obtenus avec cette approche hybride sont les suivants :

- Accuracy globale : 83 %
- Macro F1-score : 0,83
- Weighted F1-score : 0,83

Ces performances montrent une amélioration notable par rapport au CNN seul, ce qui confirme l'intérêt d'utiliser les features profondes du CNN comme entrée pour un modèle de boosting.

=== Boosting Report ===

	precision	recall	f1-score	support
COVID	0.88	0.80	0.84	723
Lung_Opacity	0.80	0.73	0.76	1203
Normal	0.82	0.90	0.85	2038
Viral Pneumonia	0.92	0.82	0.86	269
accuracy			0.83	4233
macro avg	0.85	0.81	0.83	4233
weighted avg	0.83	0.83	0.83	4233


d) Observations

Détection correcte des classes COVID et Viral Pneumonia

Réduction significative des confusions

Meilleur équilibre précision / recall

Le Boosting exploite efficacement les features profondes du CNN



8.7 Transfer Learning – Méthodologie et justification des choix

Cette section détaille et justifie chaque choix de paramètre : découpage des données, prétraitement, augmentation, architecture de la tête, gestion du déséquilibre et protocole de fine-tuning.

a) Pourquoi le Transfer Learning

Dans le protocole final de comparaison sur le découpage stratifié 70/15/15, le CNN Baseline entraîné de zéro reste inférieur aux approches de Transfer Learning : il atteint une accuracy de 0,7499 et un macro F1-score de 0,7243 sur le test figé de 3 175 images, avec un rappel COVID limité à 0,4225. Ce résultat doit être distingué du premier CNN exploratoire évalué sur un découpage 80/20, présenté plus haut, qui servait surtout à diagnostiquer les limites d'une architecture naïve. Le Transfer Learning réutilise des réseaux pré-entraînés sur ImageNet (1,2 million d'images) : leurs premières couches détectent déjà des motifs génériques (contours, textures) qu'il suffit d'adapter à la radiographie. C'est l'état de l'art pour la classification d'images médicales avec un jeu de données limité.

b) Reproductibilité (graine aléatoire 42)

La graine est fixée à 42 pour NumPy, TensorFlow et les générateurs d'images : même découpage, même ordre de mélange et mêmes tirages d'augmentation à chaque exécution. C'est indispensable pour comparer les modèles à armes égales et pour reproduire et défendre exactement les chiffres présentés.

c) Pourquoi un découpage stratifié 70 / 15 / 15

Pourquoi stratifier ? Le jeu est fortement déséquilibré (Normal 48 %, Viral Pneumonia 6 %). Un découpage purement aléatoire risquerait de sous- ou sur-représenter une classe rare dans le test, rendant la mesure instable. La stratification (paramètre stratify sur le label) garantit que chaque ensemble (train, validation, test) conserve les mêmes proportions de classes que le jeu complet.

Pourquoi 70 / 15 / 15 ? 70 % pour l'entraînement (assez de données pour fine-tuner) ; 15 % de validation, pour le réglage et les callbacks (EarlyStopping, ReduceLR) sans jamais intervenir dans la mesure finale ; 15 % de test, jamais vus, pour l'évaluation finale. Le découpage se fait en deux temps (70 % / 30 %, puis ce 30 % coupé en deux), avec random_state = 42 (déterministe). La séparation porte sur les images : une image ne peut appartenir qu'à un seul ensemble → pas de fuite de données.

Classe	Train	Validation	Test
COVID	2 531	543	542
Lung Opacity	4 208	902	902
Normal	7 134	1 529	1 529
Viral Pneumonia	942	201	202
Total	14 815	3 175	3 175

d) Taille d'image 224×224 et conversion RGB

Les images sont redimensionnées en 224×224 car ResNet50 et EfficientNetB0 ont été pré-entraînés à cette résolution ; la conserver permet de réutiliser pleinement les poids ImageNet. Les radiographies étant en niveaux de gris, elles sont chargées en 3 canaux (RGB) par réplication du canal : les poids ImageNet attendent 3 canaux. On ne fabrique pas de couleur, on respecte le format d'entrée.

e) Normalisation par preprocess_input dédié

Chaque backbone applique sa propre normalisation (`resnet50.preprocess_input` ≠ `efficientnet.preprocess_input`), celle attendue par ses poids pré-entraînés, et non un simple `/255` générique : sinon les statistiques d'entrée ne correspondraient pas à celles vues pendant l'entraînement ImageNet, dégradant les performances.

f) Augmentation de données (train uniquement) – valeurs justifiées

L'augmentation n'est appliquée qu'au train, pour accroître sa diversité et limiter le sur-apprentissage ; validation et test restent intacts. Chaque valeur reste réaliste en radiologie :

- rotation $\pm 10^\circ$: un patient n'est jamais parfaitement aligné, mais une grande rotation serait irréaliste sur un thorax.
- décalages $\pm 8\%$ (horizontal et vertical) : tolérance au cadrage.
- zoom $\pm 10\%$: variation de distance / cadrage.
- retournement horizontal : un thorax reste plausible en miroir gauche/droite.
- pas de retournement vertical : une radio retournée (cœur en haut) n'a aucun sens anatomique.
- `fill_mode = nearest` : les pixels créés par rotation/décalage sont comblés par le voisin le plus proche, évitant des bandes noires artificielles.

g) Architecture de la tête de classification

Sur le backbone gelé, on ajoute : `GlobalAveragePooling2D` → `BatchNormalization` → `Dropout(0,4)` → `Dense(128, ReLU)` → `Dropout(0,3)` → `Dense(4, Softmax)`. Le `GlobalAveragePooling` résume les cartes de caractéristiques en un vecteur compact (moins de paramètres qu'un `Flatten`, donc moins de sur-apprentissage). Les deux `Dropout` et la `BatchNormalization` régularisent et stabilisent l'apprentissage. La sortie `Softmax` à 4 neurones donne une probabilité par classe.

h) Taille de lot (batch = 32)

Compromis classique : assez grand pour des gradients stables et une bonne utilisation du matériel, assez petit pour tenir en mémoire. 32 est une valeur standard et robuste.

i) Gestion du déséquilibre – poids de classe « balanced »

Des poids de classe sont calculés avec `compute_class_weight("balanced")` sur le train uniquement (anti-fuite) : chaque classe reçoit un poids inversement proportionnel à sa fréquence. Le modèle est donc davantage pénalisé lorsqu'il se trompe sur une classe rare, ce qui l'empêche de « tout prédire Normal ».

Classe	Poids
COVID	1,463
Lung Opacity	0,880
Normal	0,519
Viral Pneumonia	3,932

j) Fine-tuning en deux phases – pourquoi ce protocole

- Phase 1 (tête seule, 10 époques, $lr = 1e-4$) : le backbone est gelé ($\approx 267\ 000$ paramètres entraînaibles sur 23,8 millions pour ResNet50). On laisse la nouvelle tête se stabiliser sans détruire les poids ImageNet par des gradients initiaux trop grands.
- Phase 2 (fine-tuning, 15 époques, $lr = 1e-5$) : on dégèle les 30 dernières couches du backbone (les plus spécifiques), les premières couches restant gelées. On recompile avec un taux d'apprentissage $10\times$ plus faible ($1e-5$) pour ajuster finement ces couches au domaine médical sans « casser » les poids pré-entraînés.

k) Callbacks

- EarlyStopping (patience 5, restauration des meilleurs poids) : arrête l'entraînement si la validation ne progresse plus → évite le sur-apprentissage et conserve le meilleur état.
- ModelCheckpoint : sauvegarde automatiquement le meilleur modèle (sur `val_loss`).
- ReduceLROnPlateau (facteur 0,3, patience 2) : réduit le taux d'apprentissage quand la validation stagne, pour affiner la convergence.

l) Métrique d'évaluation

Vu le déséquilibre, l'accuracy est trompeuse (un classifieur « tout Normal » atteindrait 48 %). La métrique de sélection est donc le macro F1-score (moyenne non pondérée des F1 par classe : chaque classe pèse autant), complétée par le rappel par classe (notamment COVID) comme garde-fou clinique.

8.8 Transfer Learning – ResNet50 (modèle retenu)

Évaluation sur le test figé (3 175 images). ResNet50 fine-tuné obtient les meilleures performances de tous les modèles testés : c'est le modèle retenu.

Performance globale

- Accuracy : 0,933
- Macro F1-score : 0,936
- Précision macro : 0,941
- Rappel macro : 0,932
- Weighted F1-score : 0,933

Classification report

Classe	Précision	Rappel	F1-score	Support
COVID	0,965	0,958	0,961	542
Lung Opacity	0,943	0,873	0,906	902
Normal	0,917	0,960	0,938	1 529
Viral Pneumonia	0,940	0,936	0,938	202
Macro avg	0,941	0,932	0,936	3 175

Observations. ResNet50 fine-tuné atteint un macro F1-score de 0,936, le meilleur de l'étude, avec un excellent équilibre sur les quatre classes : rappel COVID 0,958 (garde-fou clinique), et la classe difficile Lung Opacity est la mieux traitée de tous les modèles (rappel 0,873). C'est pourquoi il est retenu comme modèle final.

8.9 Transfer Learning – VGG16

Évaluation sur le même découpage stratifié 70 / 15 / 15 que les modèles de Transfer Learning. VGG16 fine-tuné constitue une référence supplémentaire : il améliore nettement le CNN Baseline et se classe entre ResNet50 et EfficientNetB0 sur le macro F1-score.

Performance globale

- Accuracy : 0,911
- Macro F1-score : 0,914
- Précision macro : 0,928
- Rappel macro : 0,902
- Weighted F1-score : 0,910

Classification report

Classe	Précision	Rappel	F1-score	Support
COVID	0,94	0,89	0,92	542
Lung Opacity	0,91	0,85	0,88	902
Normal	0,90	0,95	0,93	1 529
Viral Pneumonia	0,97	0,91	0,94	202
Macro avg	0,928	0,902	0,914	3 175

Observations. VGG16 obtient un macro F1-score de 0,914, supérieur à EfficientNetB0 dans cette exécution, mais reste légèrement inférieur à ResNet50. Il confirme l'intérêt du Transfer Learning tout en ne remettant pas en cause le choix final de ResNet50.

8.10 Transfer Learning – EfficientNetB0

Évaluation sur le test figé (3 175 images).

Performance globale

- Accuracy : 0,893
- Macro F1-score : 0,896
- Précision macro : 0,881
- Rappel macro : 0,913
- Weighted F1-score : 0,893

Classification report

Classe	Précision	Rappel	F1-score	Support
COVID	0,836	0,924	0,878	542
Lung Opacity	0,860	0,900	0,880	902
Normal	0,939	0,869	0,902	1 529
Viral Pneumonia	0,890	0,960	0,924	202
Macro avg	0,881	0,913	0,896	3 175

Observations. EfficientNetB0 fine-tuné atteint lui aussi un très bon niveau (macro F1 0,896), avec un bon rappel macro (0,913) et un rappel COVID de 0,924. Il reste légèrement en deçà de ResNet50 sur le F1-macro global, ce qui le place en second modèle de l'étude.

8.11 Comparaison des modèles

Les modèles ci-dessous ne reposent pas tous sur le même protocole de test : CNN Baseline, VGG16, EfficientNetB0 et ResNet50 sont évalués sur le test figé de 3 175 images, tandis que Random Forest, KNN et l'hybride CNN + Gradient Boosting sont rappelés à titre indicatif sur le découpage 80/20. La comparaison principale doit donc privilégier les modèles évalués sur le même test figé.

Modèle	Macro F1	Accuracy	Rappel COVID	Test
ResNet50 (retenu)	0,936	0,933	0,958	70/15/15 · 3 175
VGG16	0,914	0,911	0,890	70/15/15 · 3 175
EfficientNetB0	0,896	0,893	0,924	70/15/15 · 3 175
Hybride CNN + GB	0,842	0,833	0,844	80/20 · 4 233
Random Forest	0,814	0,820	0,700	80/20 · 4 233

KNN	0,770	0,774	0,670	80/20 · 4 233
CNN Baseline	0,724	0,750	0,423	70/15/15 · 3 175


Lecture. Les approches de Transfer Learning dominent les modèles classiques et le CNN Baseline. ResNet50 fine-tuné obtient le meilleur macro F1-score (0,936) et constitue le modèle final retenu. VGG16 suit avec un macro F1-score de 0,914, puis EfficientNetB0 avec 0,896. Le CNN Baseline reste le moins performant des modèles profonds évalués sur le test figé, notamment à cause de son rappel COVID limité.

8.12 Interprétabilité étendue – Grad-CAM (Transfer Learning) + SHAP


L'interprétabilité par Grad-CAM est ici étendue aux deux modèles de Transfer Learning et complétée par SHAP.

a) Grad-CAM sur ResNet50 et EfficientNetB0

Grad-CAM est appliqué aux deux modèles, sur la dernière couche convolutive : un exemple correctement classé par classe (image originale | carte de chaleur | superposition) et des cas mal classés, pour observer où le modèle regarde lorsqu'il se trompe.



Grad-CAM – ResNet50, cas COVID correctement classé.




Grad-CAM – EfficientNetB0, cas COVID correctement classé.

b) SHAP

shap.GradientExplainer (robuste sur les modèles fonctionnels Keras récents) est appliqué à un modèle de Transfer Learning : fond d'environ 24 images d'entraînement, explication de plusieurs images de test. Cette approche complète Grad-CAM en attribuant à chaque pixel une contribution (positive ou négative) à la prédiction.

Valeurs SHAP par classe - EfficientNetB0



Valeurs SHAP par classe. À gauche la radio originale ; pixels rouges = poussent vers la classe, bleus = l'en éloignent.

c) Lecture et garde-fou

Une activation localisée sur les champs pulmonaires conforte la plausibilité clinique de la prédiction. À l'inverse, une activation concentrée sur les bords, les marqueurs ou les annotations signifierait un biais d'apprentissage de raccourci (shortcut learning) : le modèle exploiterait des artefacts corrélés à la source de l'image plutôt que la pathologie. Les classes provenant de bases différentes, ce risque est réel et l'interprétabilité sert précisément à l'auditer.

8.13 Conclusion de la modélisation

La progression Baseline ML → CNN → Gradient Boosting → Transfer Learning montre un gain net et cohérent. Le modèle retenu est ResNet50 fine-tuné (macro F1 0,936, accuracy 0,933,

rappel COVID 0,958), qui obtient les meilleures performances de l'étude ; EfficientNetB0 (0,896) le suit de près. Le découpage stratifié, les poids de classe, le fine-tuning en deux phases et l'audit Grad-CAM/SHAP contribuent à rendre l'évaluation plus rigoureuse et plus défendable. Ils ne garantissent toutefois pas l'absence de biais, notamment en raison du risque de shortcut learning et de la dépendance au dataset utilisé.

8.14 Conclusions scientifiques et métiers

Les différentes expérimentations menées dans ce projet ont permis d'évaluer plusieurs approches de machine learning et de deep learning pour la classification de radiographies pulmonaires.

Les modèles classiques constituent une baseline utile : Random Forest atteint une accuracy d'environ 81,95 % et un macro F1-score de 0,814, tandis que KNN reste inférieur avec une accuracy de 77,39 % et un macro F1-score de 0,770.

Le CNN Baseline entraîné de zéro améliore l'automatisation de l'extraction de caractéristiques, mais ses performances restent limitées par rapport au Transfer Learning : accuracy de 0,7499, macro F1-score de 0,7243 et rappel COVID de 0,4225.

Les modèles pré-entraînés apportent le gain le plus net. VGG16 atteint un macro F1-score de 0,914, EfficientNetB0 atteint 0,896, et ResNet50 obtient les meilleurs résultats avec une accuracy de 0,933, un macro F1-score de 0,936 et un rappel COVID de 0,958.

D'un point de vue scientifique et applicatif, ResNet50 Fine-Tuned apparaît donc comme le modèle le plus pertinent dans le cadre expérimental de cette étude et sur le jeu de données utilisé. Les analyses Grad-CAM et SHAP suggèrent que ses prédictions s'appuient en partie sur des régions pulmonaires pertinentes, ce qui renforce son intérêt comme outil potentiel d'aide à la décision. Cependant, ces résultats ne permettent pas de conclure à une validité clinique : une validation externe sur des données hospitalières indépendantes, une analyse par des experts médicaux et une étude prospective seraient nécessaires avant toute utilisation réelle.